



Apresentação

A cada momento que passa, mais conhecimento é gerado no mundo, independentemente de quem o gere ou da qual situação em que acontece. Com o advento da Internet, esse conhecimento começou a ser compartilhado em larga escala, a ponto de atualmente ser impossível alguma pessoa no mundo conseguir consumir pelo menos 1% dele.

Com tanta informação, foi necessário o desenvolvimento de tecnologias que permitissem a catalogação e a possibilidade de filtrar e selecionar determinados itens (seja arquivo, *site*, foto ou vídeo) de acordo com o interesse de cada um. Seguindo essa linha de raciocínio, foram criados os motores de busca.

Nesta Unidade de Aprendizagem, você vai descobrir o que é um motor de busca, seu propósito e como eles funcionam. Além disso, descobrirá quais são as fontes de dados que eles usam e como fazem para organizar esses dados e aprenderá como um sistema NoSQL pode auxiliar no processo de indexação da informação em um motor de busca.

Bons estudos.

Ao final desta Unidade de Aprendizagem, você deve apresentar os seguintes aprendizados:

- Definir o motor de busca e seu funcionamento.
- Classificar os motores de busca quanto à fonte dos dados.
- Relacionar a utilização de bancos de dados NoSQL com o processo de indexação de motores de busca.









Os motores de busca são essenciais para obtenção de arquivos e dados de forma rápida e organizada, com base em interesses pontuais que se pode demonstrar a partir de "palavras-chave". Mas você já parou para pensar o que os motores fazem com essas palavras-chave?

Como é que o Google, por exemplo, devolve uma coletânea de materiais sobre o que é, como fazer, onde estudar e outras coisas sobre "aprendizado de máquina" quando você procura apenas por essas palavras? Há uma série de passos para que isso ocorra, e você pode conferi-los agora.

Veja, no Infográfico a seguir, como os motores de busca funcionam.

COMO FUNCIONAM OS MECANISMOS DE BUSCA?

No fluxo a seguir, você irá acompanhar como se dá o processo de mecanismos de busca.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.



Conteúdo do livro


Com o avanço e a presença cada vez mais evidente do *Big Data*, bancos de dados e serviços que possibilitem a manipulação de grandes volumes de dados de forma eficiente são extremamente necessários. Os bancos de dados não relacionais são importantes nesse processo, e ferramentas baseadas neles, como o motor de busca Elasticsearch, podem ser a solução para obter resultados de busca rápidos e precisos em cima dessa imensidade de dados que nos cerca.

No capítulo **Motores de busca (*search engines*)**, da obra *Banco de dados não relacional*, você vai aprender sobre a definição e a classificação dos motores de busca, um pouco da sua história e funcionamento e também como o NoSQL pode estar envolvido nesse processo.

Boa leitura.

BANCO DE DADOS NÃO RELACIONAL

Mariana Araújo Pereira



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Motores de busca (*search engines*)

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir o motor de busca e seu funcionamento.
- Classificar os motores de busca quanto à fonte dos dados.
- Relacionar a utilização de bancos de dados NoSQL com o processo de indexação de motores de busca.

Introdução

Os motores de busca são programas utilizados para encontrar diferentes páginas e documentos que possuem informações relevantes e conectadas com o interesse do usuário que está realizando a busca a partir de termos ou palavras-chave. Esses motores podem utilizar modelos probabilísticos ou booleanos nas suas buscas, bem como podem ter diferentes fontes de dados e indexação. Esta última pode ser facilitada pela utilização de bancos de dados NoSQL.

Neste capítulo, você estudará sobre os motores de busca, bem como verá de onde eles surgiram e como funcionam. Além disso, verá quais são as suas classificações e exemplos amplamente utilizados de cada uma delas. Por fim, verá como os bancos NoSQL podem ajudar na indexação de motores de busca.

1 O que são e como funcionam os motores de busca

A chamada “Era do Conhecimento”, que teve o seu início no século XX, revolucionou e ainda revoluciona o mundo como um todo, por meio do amplo número de informações geradas e disponibilizadas a cada dia. No entanto, devido ao grande volume de informações, é preciso condensar e categorizar todos esses dados de alguma forma, a fim de facilitar a sua busca de acordo com o interesse de quem está pesquisando. A preocupação em fazer isso vem desde meados dos anos 1900, antes mesmo do surgimento da internet, e se tornou pública com a idealização e publicação do Memex, em 1945, um dispositivo descrito pelo engenheiro, inventor e político estadunidense Vannevar Bush. A ideia dele era extremamente complexa e cheia de funcionalidades, dentre as quais estavam incluídas a capacidade de comprimir e armazenar toda a informação presente em livros e documentos, por exemplo, bem como permitir a sua consulta de forma rápida e eficiente (BUSH, 1945). Hoje, a descrição que Bush utilizou é considerada o conceito inicial do hipertexto ou, no mundo virtual, *hyperlink* (NYCE; KAHN, 1991), por isso, alguns o consideram como um dos grandes idealizadores do sistema de documentos hipermídia, conhecido como *web* (WWW, do inglês World Wide Web; ou Rede Mundial de Computadores, em português), e dos motores de busca que nele atuam.

Ao contrário do que algumas pessoas acreditam, o WWW e a internet são coisas diferentes. A internet é uma rede de computadores interconectados que surgiu no auge da Guerra Fria, nos anos 1960, a fim de facilitar a conexão entre laboratórios, e somente começou a se popularizar no fim dos anos 80, com a abertura da sua utilização comercial. Em contrapartida, o WWW é um sistema de informação global que funciona dentro da internet, criado no início dos anos 90 com o objetivo de desenvolver uma interface de fácil acesso a informações, utilizando, principalmente, o *hyperlink* (i.e., o endereço do *site*, com o *www* na frente), permitindo, assim, que pessoas de diferentes localidades tivessem acesso ao mesmo documento.



Saiba mais

No artigo publicado em 1992 por Tim Berners Lee, criador do WWW, Caillau e Groff, já há menção sobre ferramentas de busca que facilitassem o acesso para além do *hyperlink* (BERNERS-LEE; CAILLAU; GROFF, 1992).

Em 1990, o primeiro motor de busca foi publicado, ainda baseado na internet *pré-web*. O Archie era um diretório de serviço para a internet que tinha como objetivo fornecer não só informações de documentos, mas também nomes e contatos de pessoas e serviços ligados a eles (EMTAGE; DEUTSCH, 1992). Esse mecanismo se manteve em alta por alguns anos, mas foi rapidamente substituído por outros motores *pós-web*.

Portanto, os motores de busca são programas desenvolvidos para pesquisar e localizar informações relevantes por meio de termos inseridos pelos usuários, fornecendo uma lista dos *sites* e arquivos que mais correspondem àquela busca com base nos termos pesquisados (TARAKESWAR; KAVITHA, 2011).

Funcionamento dos motores de busca

O processo necessário para o funcionamento dos motores de busca começa antes mesmo de o usuário pensar em utilizá-los. Como o conteúdo presente na *web* é muito vasto, os motores de busca utilizam *software* rastreadores que detectam as páginas disponíveis para o público, analisam o conteúdo e os *links* de cada página e extraem dados para catalogar e classificar cada uma delas. Os *software* responsáveis por esse processo são conhecidos como rastreadores *web*, aranhas ou *web crawler*. Informações como classificação etária e palavras-chave são registradas em um tipo de índice de pesquisa. No caso do Google Search, que atualmente é o motor de busca mais utilizado, esse índice que armazena dados de bilhões de páginas possui um tamanho superior a 100 milhões de gigabytes e tende a crescer cada vez mais, devido à sua constante atualização e ao aumento de materiais disponíveis na rede (COMO..., [2020?]).



Fique atento

Os *web crawlers* são *software* capazes de realizar varreduras sistematicamente em toda a internet, constituindo a base dos motores de busca. Por meio da obtenção de informações utilizando os textos e as palavras-chave das páginas digitadas, eles possibilitam a indexação dos *sites* nas “bibliotecas” dos motores de busca e o rápido retorno de resultados quando o usuário realiza uma operação de busca. Os *web crawlers* mais famosos são: Googlebot, da Google; Yahoo! Sluro, do Yahoo!; e Msnbot, da Microsoft.

O registro das informações e a criação de um índice de pesquisa fazem parte de um processo chamado de **indexação**. Ao encontrar uma página, o rastreador precisa “entender” do que ela fala e o que contém, analisando não só o texto, mas também imagens, vídeos e áudios ali presentes e salvando essas informações no banco de dados. Além disso, esses itens coletados são utilizados para identificar conteúdos duplicados, em que, no exemplo do Google, as “cópias” recebem uma penalização do índice, sendo exibidas em uma posição e frequência menor (COMO..., [2020?]). Em virtude da constante atualização de páginas, algumas verificações são constantemente feitas, como a “revisitação” das páginas indexadas, com o objetivo de encontrar e catalogar possíveis mudanças que ocorreram nelas (TARAKESWAR; KAVITHA, 2011). Com o índice de pesquisa estabelecido, a pesquisa propriamente dita pode ser realizada.

De forma geral, os motores de busca estruturam os resultados da pesquisa de acordo com a relevância da página. Embora muitos fatores possam influenciar a relevância, existem dois princípios gerais para determinar o quão relevante o conteúdo é: a localização das palavras-chave dentro do arquivo; e a frequência em que elas aparecem. Assim, as páginas nas quais o termo de pesquisa aparece mais vezes e está inserido no início da página, nos *links*, subtítulos e *tags* são consideradas mais relevantes e podem aparecer nas primeiras posições dos resultados das pesquisas. No entanto, cada mecanismo de pesquisa possui seu próprio método para atribuir pesos a cada característica das páginas. Isso explica por que, para a mesma pesquisa, diferentes motores de pesquisas fornecem resultados ordenados de modo diverso (TARAKESWAR; KAVITHA, 2011).

Após a inserção de frases e palavras na barra de busca, faz-se necessário que os algoritmos por trás dos motores realizem algumas ações, como: analisar o significado de cada palavra inserida, considerando possíveis erros de digitação (p. ex., “mangs”, em vez de “manga”) e contextos específicos (p. ex., “manga” da blusa ou a fruta?); buscar por dicas para identificar uma necessidade de informação ampla ou específica (p. ex., horário de funcionamento de um estabelecimento); e tentar identificar se os resultados devem ser locais ou globais e se o usuário procura por notícias antigas ou recentes. Tudo isso é realizado a partir de modelos linguísticos e aplicações de estudos sobre a compreensão da linguagem natural.


Ao pensar na inserção de termos soltos na barra de busca, torna-se evidente a necessidade de que haja uma forma de realizar a busca com diferentes termos, reconhecendo-os individualmente, em vez de considerar um grupo de palavras-chave como uma única entrada de pesquisa. Por exemplo, a frase “amarelo, lápis, xícara” não faz sentido algum, porém, se você inseri-la em um motor de busca qualquer, certamente obterá resultados de xícaras ou lápis amarelos e, muitas vezes, os três itens em conjunto (Figura 1). Na maioria das vezes, isso é possível por meio do operador booleano AND, que está implícito nas barras de busca e tem a função de dizer para o algoritmo que ele deve buscar “amarelo” E “lápis” E “xícara”.



Saiba mais

Os **operadores booleanos** são palavras que informam ao sistema de busca como combinar os termos da pesquisa. Além do AND, há também OR, NOT e suas combinações, que, em português, correspondem a E, OU e NÃO, respectivamente. Em geral, eles podem ser utilizados explicitamente pelos usuários nas opções de busca avançada, sempre em maiúsculo. Os operadores booleanos são utilizados como filtros que selecionam conjuntos de documentos para modificar a classificação, pois encontram páginas altamente relevantes (YOSHIOKA; HARAGUCHI, 2005).

Além de todos esses critérios, como o número de vezes que a palavra aparece, a análise das palavras e os indicadores booleanos implícitos ou explícitos, há mais um ponto importante para classificar a relevância das páginas: o modelo utilizado para realizar os cálculos, que geralmente são booleanos ou probabilísticos. O **modelo booleano** é o mais antigo e simples, pois usa a correspondência exata entre os termos de busca e os documentos. Dessa forma, um documento é julgado apenas como relevante ou irrelevante, sem meio-termo. Com o **modelo probabilístico**, por sua vez, é possível estimar a probabilidade de o usuário achar um documento específico relevante ou não, para além da correspondência de termos. Melhorias no modelo probabilístico podem ser feitas com inferência bayesiana.



Saiba mais

A **aprendizagem bayesiana** fornece um método para calcular a probabilidade assumida, com base nos registros de visita a *sites* anteriores do usuário para inferir qual resultado o agradaria mais, tornando o sistema, de certa forma, personalizado (ZHAO, 2018).

2 Tipos de motores de busca

Os motores de busca podem ser classificados quanto à sua indexação ou quanto à sua fonte de dados. Quando classificados quanto à sua indexação, eles podem ser divididos nos tipos listados a seguir.

- **Motores de busca por rastreador:** são aqueles que utilizam um rastreador, *bot* ou *spider* para rastrear e indexar novos conteúdos no banco de dados de pesquisa. Esse mecanismo contém três partes: o **rastreador** propriamente dito, o **índice** e o **software do mecanismo de pesquisa**. Em virtude do rastreio constante, é o mecanismo que fornece informações mais atualizadas. O Ask é um exemplo de motor de busca baseado em rastreador.
- **Motores de busca manuais:** são mecanismos de pesquisa que dependem de atividade humana para realizar a indexação dos dados. Ou seja, o próprio dono da página da *web* precisa definir qual é o endereço, o título e a descrição do site. Além disso, a submissão da página precisa ser revisada pelos editores. A indexação manual também pode ser realizada a partir de documentos não digitais, que serão transcritos com os campos de interesse predefinidos para a realização da indexação. Desse modo, a qualidade do conteúdo acaba sendo melhor, mas qualquer alteração realizada não será atualizada no mecanismo de busca até que o conteúdo seja enviado novamente de modo manual, o que limita a busca por resultados mais recentes sobre determinados assuntos. Alguns mecanismos especializados, como os motores de busca de genealogia, são alimentados dessa forma.
- **Motores de busca híbridos:** incluem os recursos dos motores de busca por rastreador e manual, como é possível perceber no Quadro 1. O Google Search é um exemplo de mecanismo híbrido (TARAKESWAR; KAVITHA, 2011).

Quadro 1. Comparação entre os motores de busca por rastreo, manual e híbrido

	Rastreador	Manual	Híbrido
Indexação por robôs	×		×
Indexação manual		×	×
Dados sempre atualizados	×		×
Dados mais confiáveis e curados		×	×

A seguir são listados os motores de busca que são classificados quanto à sua fonte de dados.

- **Metadados:** a maior parte dos motores de busca da internet utiliza como fonte de dados os metadados de arquivos e *sites*. Esses metadados nada mais são do que as informações sobre os dados que ali estão contidos, salvas em arquivos “invisíveis”, o que inclui as palavras-chave. Então, a indexação das informações é realizada a partir do que está presente nos metadados, muitas vezes em campos bem-definidos, conforme a Figura 2.
- **Federados:** por meio dos dados federados, é possível realizar uma mesma pesquisa em diferentes bancos de dados, *sites* e repositórios com as informações já indexadas em cada um deles. Nesse caso, a pesquisa é realizada de forma paralela, e os resultados são mesclados antes de serem exibidos como um “resultado final” para o usuário. Essa forma de pesquisa em diferentes fontes utilizando a indexação de cada base é chamada de **pesquisa federada** (MELTON; BUXTON, 2011). O Google Scholar é um exemplo de motor de busca que utiliza pesquisa federada.

```
<title> A tag title está aqui </title>

<meta name = "description" content = "E o texto descritivo que entra aqui é a meta
descrição.">

<meta name = "keywords" content = "" />
```

Figura 2. Exemplo de metadados de um *site*.

- **Por *desktop*:** essa fonte de dados não está relacionada à internet, mas é muito utilizada por todos nós. O *desktop* armazena tudo que está no nosso computador físico. Assim, os motores de busca cujas fontes são o *desktop* não funcionam na internet, mas na própria máquina. Esse motor de busca é utilizado para buscar por arquivos, músicas, filmes e textos, por exemplo, nas centenas de pastas existentes em um computador. O Windows Search é o motor desse tipo mais utilizado, presente nos sistemas operacionais Windows. Esses motores realizam as etapas de busca e indexação de forma contínua, mantendo o índice sempre atualizado. Nesse processo, os tipos principais de informação recolhidos são o nome do arquivo, o caminho ou localização, os metadados e o conteúdo (WINDOWS..., 2018).

3 A importância do NoSQL para o desenvolvimento de motores de busca

O NoSQL é uma tecnologia que significa, literalmente, “não apenas SQL” (do inglês *not only SQL*), utilizada em bancos de dados não relacionais. Esses bancos não seguem a linguagem de busca estruturada, o que facilita o armazenamento de grandes volumes de dados com alta escalabilidade (i.e., capacidade de aumentar o tamanho e o processamento de acordo com a demanda) e disponibilidade (HIRIYANNAIAH *et al.*, 2018). Portanto, os bancos NoSQL são ideais para estar por trás de um motor de busca, pois armazenam as informações cada vez mais crescentes durante a indexação e facilitam os resultados das pesquisas de acordo com os critérios estabelecidos. Alguns exemplos de NoSQLs que facilitam a pesquisa de alta qualidade são: Apache Lucene, Apache Solr e Elasticsearch (MCCREARY; KELLY, 2014), que será o foco desta seção.

Os sistemas baseados em NoSQL utilizam algumas estratégias para tornar os mecanismos de pesquisa mais eficazes, as quais são descritas seguir.

- **Índice de intervalo:** forma de indexar todos os valores de cada item do banco de dados em ordem crescente. É ideal para palavras-chave alfabéticas e datas, por exemplo.
- **Índice reverso:** para cada palavra em uma coleção de documentos, há uma lista de todos os documentos que contêm essa palavra, utilizada para acelerar a pesquisa de documentos que contêm palavras-chave.

- **Classificação da pesquisa por relevância:** calcula a probabilidade de aquela página corresponder ao que usuário procura, baseando-se na quantidade de palavras-chave, no tipo de documento, na avaliação de conteúdos, entre outros fatores.



Fique atento

Consulta e **pesquisa** podem parecer sinônimos, mas, nesse contexto, possuem resultados distintos. A consulta é aquela em que apenas os resultados que correspondem aos termos inseridos são exibidos. Já a pesquisa pode incluir termos opcionais, fornecendo resultados ordenados por relevância.

O Elasticsearch é um motor de pesquisa orientado a documentos, gratuito e de código aberto, baseado no Apache Lucene. Ele permite o armazenamento de dados centralmente, proporcionando uma busca rápida e um cálculo de relevância com ajuste fino e analítico, podendo ser ampliado com facilidade. De acordo com os distribuidores, o Elasticsearch pode ser utilizado para realizar buscas em aplicativos e *websites* ou para buscas de cunho empresarial, além de outras funções de análise e monitoramento de dados (ELASTIC, c2020). Além disso, ele aceita dados de diferentes tipos e fontes.

Após a análise dos dados brutos, ocorre a indexação, em que os dados são salvos em documentos do tipo JSON, e o índice é formado pelo conjunto de documentos relacionados entre si. Cada documento possui um conjunto de chaves (p. ex., nomes de campos) que está relacionado aos seus valores (que podem ser nomes, números, datas, etc.). A estratégia utilizada pelo Elasticsearch na estruturação dos dados é o índice invertido. Assim, durante o processo de indexação, o Elasticsearch armazena os documentos e desenvolve um índice invertido para tornar os dados contidos ali “buscáveis”, praticamente em tempo real (ELASTIC, c2020).

Por ser um sistema distribuído, os índices podem ser divididos em diferentes *shards* (partições), que podem ser replicados. Ou seja, há uma maior consistência na criação dos índices, com maior tolerância a falhas no servidor, já que é possível recuperar os índices em outras partições, mesmo que a partição principal falhe. Além disso, o Elasticsearch suporta facetagem e percolação, sendo útil para notificar quando um novo documento corresponde à consulta registrada.



Saiba mais

Percolação é um método de pesquisa reverso em que, em vez de retornar todos os documentos correspondentes ao que foi pesquisado, são retornados todos os resultados de pesquisa já armazenados que correspondem a um documento.

O ElasticSearch pode ser implantado e gerenciado de diferentes formas, seja por meio de serviços consolidados, como o ElasticSearch Service, que está disponível na Amazon Web Services (AWS), no Google Cloud Platform (GCP) e no Alibaba Cloud, seja por meio do *download* e da instalação dele no seu próprio *hardware* ou serviço de armazenamento em nuvem. Além disso, mais de 10 aplicações foram desenvolvidas com base nele, com o objetivo de aprimorar os sistemas de análises e buscas de dados, como o Elastic App Search e o Elastic Site Search.

No caso do Elastic App Search, é possível utilizar a capacidade concentrada do ElasticSearch em conjunto com diferentes APIs (Application Programming Interface; ou Interface de Programação de Aplicações, em português) e painéis intuitivos. Nele, existem recursos de tolerância a erros de digitação, bem como a possibilidade de calibrar a relevância da busca a partir de conjuntos de sinônimos, reordenar os resultados para uma determinada consulta e atribuir pesos distintos para fazer um ajuste fino da precisão geral. Já o Elastic Site Search possibilita uma busca avançada de *sites* de modo prático e rápido. O seu rastreador é livre de manutenção e permite a personalização intuitiva e a análise robusta dos resultados de busca. Empresas como SurveyMonkey e Shopify utilizam esse sistema em seus *sites*.



Saiba mais

Para aprender a criar uma tabela e realizar buscas em um banco NoSQL, acesse a página do guia “Crie e consulte uma tabela NoSQL”, publicado na página da Amazon Web Services (AWS).

Como visto, os motores de busca facilitam a obtenção de conhecimento e a organização e a manipulação de dados, tornando-se fundamentais para o desenvolvimento de atividades essenciais na área da tecnologia. Desse modo, é indiscutível a importância e a usabilidade dessas ferramentas no nosso dia a dia, seja por aplicações do ElasticSearch ou de motores de busca de abrangência global, seja por uma aplicação para *web* ou para os arquivos do seu computador pessoal.



Referências

BERNERS-LEE, T. J.; CAILLIAU, R.; GROFF, J.-F. The world-wide web. *Computer Networks and ISDN Systems*, North Holland, v. 25, n. 4-5, p. 454-459, 1992.

BUSH, V. As we may think. *The Atlantic Monthly*, Boston, v. 176, n. 1, p. 101-108, 1945.

COMO funciona a pesquisa Google. In: GOOGLE. Mountain View, [2020?]. Disponível em: <https://www.google.com/search/howsearchworks/>. Acesso em: 9 jun. 2020.

ELASTIC. *Elasticsearch*. Mountain View, c2020. Disponível em: <https://www.elastic.co/pt/elasticsearch/>. Acesso em: 18 jun. 2020.

EMTAGE, A.; DEUTSCH, P. Archie: an electronic directory service for the internet. In: USENIX CONFERENCE, 1992, Quebec. *Anais...* San Francisco: USENIX, 1992. p. 93-110.

HIRIYANNAIAH, S. *et al.* Semi-structured data analysis and visualisation using NoSQL. *International Journal of Big Data Intelligence, [s. l.]*, v. 5, n. 3, p. 133-142, 2018. Disponível em: <https://www.inderscience.com/info/inarticle.php?artid=92657>. Acesso em: 9 jun. 2020.

MCCREARY D. G.; KELLY, A. M. *Making sense of NoSQL: a guide for managers and the rest of us*. Shelter Island: Manning, 2014.

MELTON, J.; BUXTON, S. *Querying XML: XQuery, XPath, and SQL/XML in context*. Burlington: Morgan Kaufmann, 2011.

NYCE, J. M.; KAHN, P. (Ed.). *From memex to hypertext: Vannevar Bush and the mind's machine*. Cambridge: Academic Press, 1991.

TARAKESWAR, K.; KAVITHA, D. Search engines: a study. *Journal of Computer Applications*, New York, v. 4, n. 1, p. 29-33, 2011.

WINDOWS search overview. In: MICROSOFT. Redmond, 31 may 2018. Disponível em: <https://docs.microsoft.com/en-us/windows/win32/search/-search-3x-wds-overview>. Acesso em: 9 jun. 2020.

YOSHIOKA, M.; HARAGUCHI, M. On a combination of probabilistic and boolean ir models for WWW document retrieval. *ACM Transactions on Asian Language Information Processing*, [s. l.], v. 4, n. 3, p. 340-356, 2005.

ZHAO, Y. The application of Bayesian learning in the search engine. *Wireless Personal Communications*, [s. l.], v. 103, n. 2, p. 1121-1131, 2018.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Dica do professor

A Amazon é a empresa mais valiosa do mundo. Seu segmento de atuação é amplo, como no desenvolvimento de inteligência artificial, por exemplo, ao mesmo tempo que se mostra grande referência no comércio eletrônico.

Este último tem-se expandido nos últimos tempos, tornando-se, inclusive, o maior ponto de partida dos clientes na hora de buscar por fornecedores para realizar a compra de diferentes itens. Parte disso se deve ao excelente motor de busca desenvolvido pela empresa, o A9, que é muito mais focado em qual produto é mais atraente ao cliente do que em quais resultados simplesmente correspondem àquela pesquisa.

Na Dica do Professor, conheça um pouco mais sobre esse motor de busca e veja por que ele é tão importante para a notoriedade da Amazon nesse ramo.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.



Saiba mais

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Recuperação de informação – conceitos e tecnologia das máquinas de busca

No capítulo 6, "Linguagens de consulta", aprenda um pouco sobre os diferentes tipos de consulta e as diferentes formas de linguagem que podem ser utilizados para a realização de pesquisas nos mecanismos de busca.

Conteúdo interativo disponível na plataforma de ensino!

Como a busca do Google realmente funciona

Neste artigo, conheça nos mínimos detalhes como a busca do Google Search funciona, incluindo descrições de ferramentas como o RankBrain e o Knowledge Graph.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Como fazer Scrapy com Python para iniciantes

No capítulo, conheça a extração de dados de páginas a partir de ferramentas de rastreamento Web. Neste tutorial, aprenda a extrair informações de uma página a partir do método Scrapy utilizando a linguagem Python.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.